


Pipeline de Dados em Nuvem para Aprendizagem de Máquina



Previsão de violação de SLA em chamados de suporte técnico



Grupo: João Paulo A. S. Monteiro, Rogério B. dos Anjos e Pedro Felipe de Moraes Carcio



IFG - Pós-Graduação em IA Aplicada - Módulo 2



Profs. Sirlon Diniz - Raphael Gomes - Otávio Calaça



Goiânia, jun/2026

Visão geral da solução

Do dado bruto à decisão do gestor de suporte

Problema: antecipar quais chamados vão violar o SLA de resolução.



Domínio: suporte técnico (service desk SaaS)



Decisor: gestor da equipe de suporte



Decisão: priorizar a fila e realocar agentes antes de o prazo estourar



Tarefa de ML: classificação binária (sla_breach)



8.000

chamados



23%

violam SLA



4.0

CSAT médio



Stack do projeto



Python, Airflow, dbt



Snowflake / DuckDB



AWS (S3, Lambda, CloudFormation), Metabase

Dados utilizados e atributos extraídos

3 fontes: estruturada + não estruturada + semiestruturada

Fonte	Tipo	Conteúdo
 tickets.csv	Estruturado	categoria, prioridade, canal, tier, tempos, CSAT
 ticket_messages.jsonl	Não estruturado	texto livre do cliente
 ticket_events.json	Semiestruturado	trilha de eventos/status (JSON)

Atributos extraídos:



Texto: comprimento, nº palavras, urgência (léxico), flags (reembolso, cancelamento, erro)



Logs: nº de eventos, mudanças de status, reabertura



Estruturado: limpeza, padronização, tratamento de ausentes, partes de data



Sem vazamento de dados



A decisão ocorre logo após a 1ª resposta.



Por isso NÃO usamos como atributo:

- o tempo de resolução (desfecho)
- o CSAT (só existe no fim)



Resultado: tabela mart_ml_features com 25 atributos + alvo.


ARQUITETURA EQUIVALENTE 100% EM AWS

PIPELINE DE SUPORTE TÉCNICO



ORQUESTRAÇÃO - AMAZON MWAA (APACHE AIRFLOW GERENCIADO)

Agenda e encadeia todas as etapas do pipeline



SERVIÇOS DE SUPORTE E GOVERNANÇA



AMAZON CLOUDWATCH Monitoramento

Coleta de logs, métricas e alarmes para observabilidade de todo o pipeline.



AWS IAM + KMS Segurança

Gerenciamento de identidades, permissões (IAM) e criptografia de dados (KMS).



AWS CLOUDFORMATION
Infraestrutura como Código
Provisionamento e versionamento de toda a infraestrutura via código (YAML).



GESTOR DE SUPORTE Priorização de Chamados

Fila priorizada com base no risco de SLA e criticidade dos chamados.



100% AWS NATIVE
Serviços gerenciados, escaláveis e seguros.



ALTA ESCALABILIDADE
Processamento elástico e armazenamento ilimitado.



CONFIABILIDADE
Alta disponibilidade e tolerância a falhas.



SEGURANÇA END-TO-END
Criptografia, controle de acesso e compliance.



INSIGHTS & AUTOMAÇÃO
Dados transformados em decisões e automação ponta a ponta.

Legenda: Orquestração Ingestão Armazenamento Processamento / Analytics ML / Inferência Visualização Obs. & Segurança Gestão

Pipeline de ELT

— ...

Airflow orquestra; dbt transforma no Snowflake



Camadas dbt:



Staging: stg_tickets, stg_text_features, stg_log_features, stg_predictions



Dimensões: dim_channel, dim_product, dim_category, dim_date



Fatos/marts: fct_tickets, mart_ml_features, fct_predictions, mart_ticket_decision



Qualidade de dados (dbt)



10 testes: not_null, unique, accepted_values, relationships



Última execução: PASS=22, 0 erros




Reproduzível: run_pipeline.py roda tudo em ~5s

Resultados do modelo de ML

KNN (hard-code + biblioteca), SVM e MLP

Modelo	Acc	Prec	Recall	F1	AUC
Baseline (regra)	0.771	0.498	0.629	0.556	0.721
KNN (na mão)	0.838	0.762	0.421	0.542	0.882
KNN (sklearn)	0.838	0.762	0.421	0.542	0.882
SVM *	0.903	0.854	0.693	0.765	0.953
MLP	0.887	0.747	0.765	0.756	0.944

* modelo de produção



Matriz de confusão e curva ROC (conjunto de teste)




- **KNN na mão** (NumPy) e scikit-learn ficaram **IDÊNTICOS**: concordância de 100% nas predições.



- **SVM** teve o melhor F1 (0,77) e AUC (0,95), sendo escolhido como modelo de produção.

Dashboard de apoio à decisão (1/2)

Indicadores e onde o SLA estoura — Metabase sobre o schema analytics




No topo, os **3 filtros** — prioridade, categoria e canal — recortam o painel inteiro. Filtrando **Critica**, a taxa de violação sobe de **22,8%** para **60,4%**.

Dashboard de apoio à decisão (2/2)

...

A fila prioritizada pelo modelo e a confiança na previsão



O CARD QUE DECIDE

Fila prioritizada por risco: chamados ordenados pela probabilidade prevista de violar o SLA — realocar agente antes do prazo estourar.

CONFIANÇA NA RECOMENDAÇÃO

A matriz de confusão fica no próprio painel: o gestor vê a recomendação e o quanto ela acerta na mesma tela.

PROVISIONADO POR SCRIPT

Um make run cria usuário, conexão, os 10 cards e os filtros do zero, via API do Metabase.

Orquestração no Airflow

DAG pipeline_suporte_tecnico — 9 tasks, execução 9/9 SUCCESS

 Airflow

DAGs

Cluster Activity

Datasets

Security

Browse

Admin

Docs

DAG

Run

pipeline_suporte_tecnico / ▶ 2026-08-16, 00:00:00 UTC

Clear

Mark state as...

Details

Graph

Gantt

Code

Event Log

ingestao

success

BashOperator

processamento_atributos

success

BashOperator

treino_avaliacao_ml

success

BashOperator

carga_warehouse

success

BashOperator

dbt_build

success

BashOperator

export_dashboard

success

BashOperator

publicar_bi_postgres

success

BashOperator

dashboard_metabase

success

BashOperator

upload_s3

success

BashOperator

ingestao

processamento_atributos

treino_avaliacao_ml

carga_warehouse

dbt_build

export_dashboard

publicar_bi_postgres

dashboard_metabase

upload_s3

ISOLAMENTO DE DEPENDÊNCIAS

O Airflow fixa versões que conflitam com o dbt. Cada task roda via **BashOperator** em um **virtualenv separado** — o scheduler apenas orquestra.

EVIDÊNCIA

9/9 tasks **SUCCESS**, registradas em **evidencias/airflow_dag_run.log**.

schedule @daily

localhost:8081

TRECHO DE EVIDENCIAS/AIRFLOW_DAG_RUN.LOG

ESTADO FINAL: SUCCESS (9/9 tasks)

[processing] ml_features: (8000, 26) -> data/processed/ml_features.csv

[warehouse] DuckDB pronto | Postgres pronto em postgres:5432/suporte_dw

Done. PASS=22 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=22

[s3] 11 arquivos enviados para s3://suporte-sla-entrega-.../suporte-sla/

A DAG executa as **mesmas etapas** do pipeline: ingestão → atributos → ML → dbt → Postgres → Metabase → S3. Comando: **make airflow-run**.

Decisões que a solução apoia



Priorizar a fila

Atacar primeiro os chamados com maior probabilidade de violar o SLA.



Realocar agentes

Direcionar esforço para prioridade Crítica/Alta e categorias mais demoradas.



Agir na estrutura

Bug/Defeito e Solicitação de Recurso concentram as violações: base de conhecimento e automações.



Acompanhar no tempo

Monitorar a evolução mensal da taxa de violação e do CSAT.